Trabajo Práctico Especial

Fundamentos de la Ciencia de Datos

Análisis sobre la Encuesta de Desarrolladores de Stack Overflow

Integrantes: Thiago Agustín Grigera, Kevin Heiland, Francisco Iturraspe

Docente a cargo: Daniela Godoy

Fecha de entrega: 10/11/2026

Año de Cursada: 2026

1. Introducción

La informática es un área de estudio y trabajo globalizada que cada día se vuelve más importante en cada vez más áreas (y más diversas). Sin embargo a la hora de elegir la informática como vocación nos vemos obligados a colaborar y competir con personas de distintas generaciones, distintos entornos, distintas sociedades. Además es un campo que se ve fuertemente amenazado por los avances tecnológicos; la IA, los frameworks nuevos que se publican cada cortos periodos de tiempo son algunos de los aspectos que nos hacen sentir que siempre nos estamos quedando atrás, que siempre hay alguien mejor capacitado para realizar nuestra tarea.

Afortunadamente hay comunidades activas de informáticos que nos ayudan a entender que el amarillismo de las noticias no siempre se condice con la realidad. Un gran ejemplo es Stack Overflow fue y sigue siendo un sitio de gran ayuda para resolver consultas sobre bugs, problemas de compatibilidad de versiones (y actualizaciones). En 2025 realizó una encuesta que se concentró en capturar información sobre los distintos usuarios de la página en donde les preguntaban sobre gran cantidad de aspectos, desde preguntas características, pasando por preferencias y experiencias tanto tecnológicas como laborales, preguntas sobre el uso de la página y sobre el uso de la IA. El conjunto cuenta con gran cantidad de información, en ciertas variables mal organizada, en otras con gran presencia de nulos. Para entender y trabajar mejor las variables utilizamos Kaggle, un sitio que tiene las preguntas que se hicieron en cada variable lo que nos ayuda a entender de dónde vienen los valores y qué variables fueron creadas para ayudar en el análisis.

Las preguntas abordan 5 secciones las cuales son: “Learning and Career (23 preguntas)”, “Tech and Tech Culture (20 preguntas)”, “Community (10 preguntas”, “AI (20 preguntas)” y “Final Thoughts (3 preguntas)”. Con estas secciones se construyó un dataset de 172 columnas y más de 49.000 registros (link).

Nos pareció importante analizar si las opiniones que popularmente se dicen sobre el mundo del software son realmente ciertas. En la sección 3 abordamos distintas hipótesis que nos permiten ver y sacar distintas conclusiones sobre la información que nos brindan los datos.

2. Análisis exploratorio de los datos

Antes de empezar con las hipótesis, nos pareció interesante detallar distintos escenarios que nos permitieron decidir cuáles plantear.

Como ya se explicó, el dataset es grande y presenta problemas de calidad, aunque tenemos la ventaja de que no hay muchas variables con lenguaje natural, las cuales siempre complican la limpieza de los datos.

La primera decisión que tomamos fue ignorar las variables Have Worked With, WantToWorkWith, Admired, HaveEntry y WantEntry porque consideramos que eran variables muy difíciles de trabajar y que no aportan mucho a nuestro análisis; además, las últimas eran variables construidas a posteriori que no estaban explicadas en el sitio de Kaggle y tenían gran cantidad de nulos (link).

Luego decidimos separar las variables TechEndorse, TechOppose, JobSatPoints y SO_Actions. No decidimos eliminarlas completamente porque podían ser útiles luego, pero sí decidimos apartarlas porque interfieren en el análisis del dataset y volvían más difícil pensar propuestas para las hipótesis con tantos números de por medio.

Con estos cambios nos quedamos con 80 columnas aproximadamente que, aunque siguen siendo muchas para manejar a mano, son más fáciles de recorrer.

Comenzamos a trabajar con las variables cualitativas que podemos cuantificar con distintas técnicas: en OrgSize y Age, por ejemplo, hicimos mapeos para llevar a números la información que tenían dentro; DevType e Industry fueron codificadas con la técnica de One-Hot Encoding.

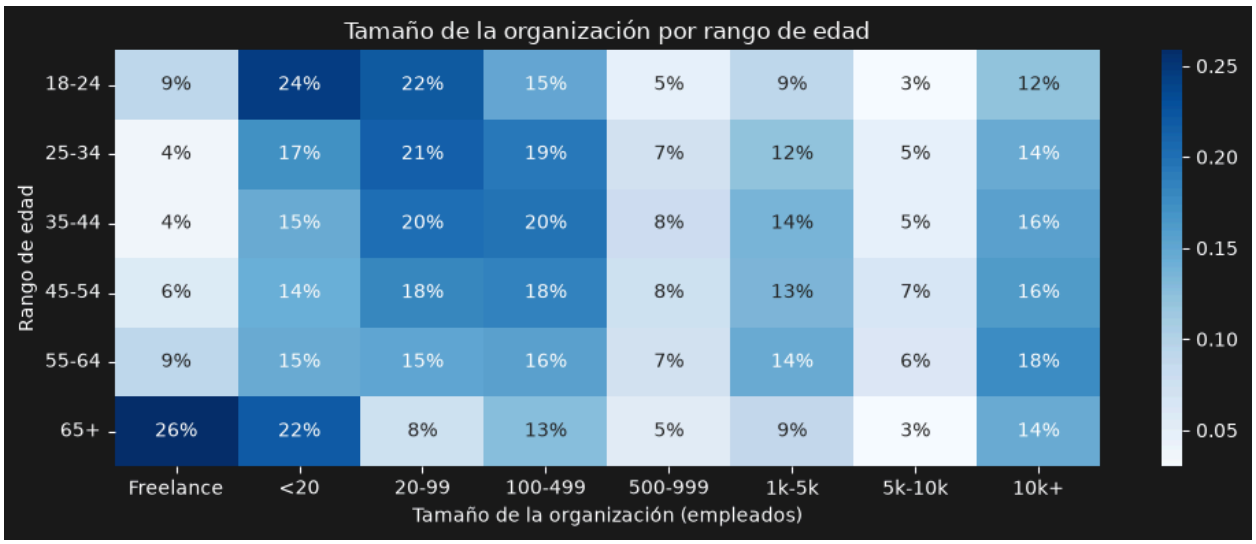
Estábamos buscando más variables para trabajar y notamos algo interesante: la sección de IA tenía muchas preguntas de estilo Likert, donde se puntúa en 5 categorías ordenadas la satisfacción, el gusto o la concordancia con la afirmación. Con esto en mente, pudimos trabajar con AISent y AIAcc, que definen el sentimiento y la confianza hacia la IA.

No podíamos encontrar la sección de agentes en el dataset hasta que descubrimos que estaba transformada de manera extraña: las preguntas estaban listadas como opciones de variables (AIAgentagree, Aiagentdesagree, etcétera). Entonces hicimos un proceso para reconstruir las variables originales y decidimos quedarnos con un promedio de las respuestas de cada sección para tener una nueva variable continua para trabajar.

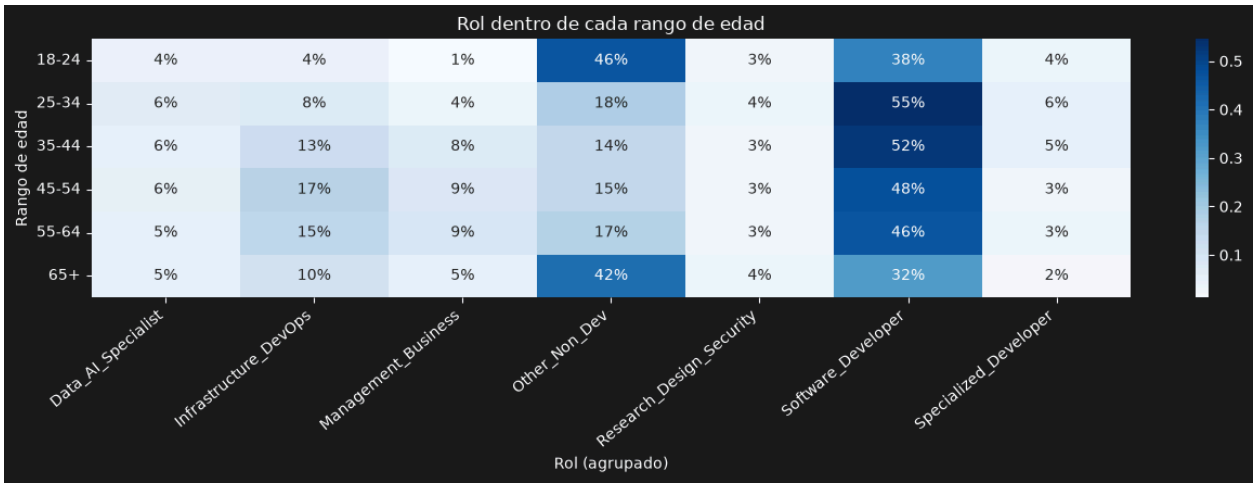
Tratamos de completar los nulos de muchas variables, pero no queríamos completar por moda ni rellenar cuando había muchos datos faltantes, además a veces no podíamos asegurar la aleatoriedad de la ausencia de los datos como en WorkExp y YearsCode. Lo que sí hicimos fue quitar los valores sospechosos como quienes afirmaban trabajar o escribir código hace más de 50 años y también quitamos los valores que no se corresponden con su rango de edad (link).

Una variable que nos resultó interesante fue OpSysPersonal use, ya que popularmente se suele decir que la comunidad tech es muy fiel al software libre y fácilmente podríamos contrastar esta opinión con la realidad de los datos. Otra cosa que notamos que podíamos abordar era que la satisfacción laboral podría estar relacionada con distintas cosas; en un principio pensamos que se podía relacionar con las opiniones sobre la IA, pero lo descartamos fácilmente con la correlación. Luego recordamos que se suele decir que el trabajo remoto es uno de los grandes beneficios de trabajar en el mundo del software, así que pensamos que podía ser interesante confirmar o rebatir esta opinión.

En el proceso de limpieza notamos que la edad podía ser un eje divisor de distintas categorías, por eso pensamos en cruzar esa variable con el tamaño de organización y luego con las categorías que habíamos definido en DevType (link).

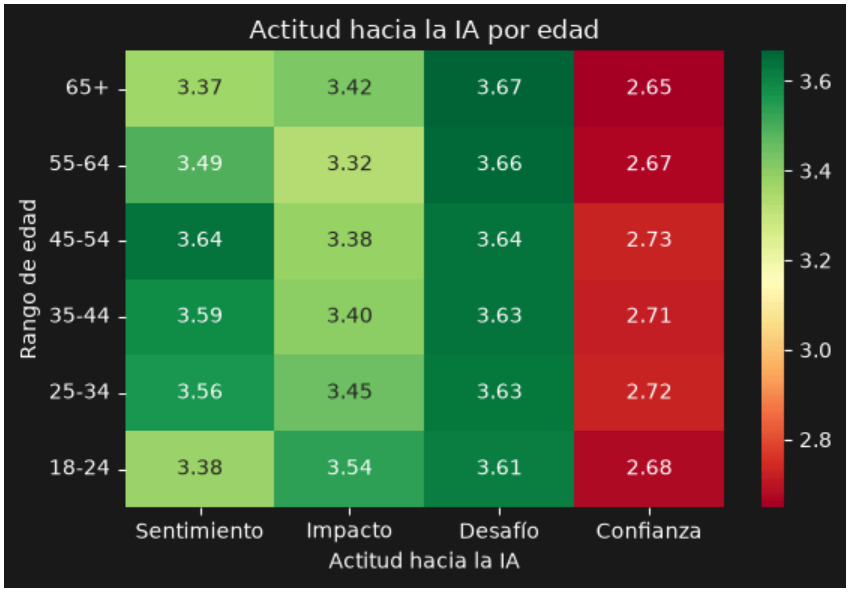


En esta tabla se ve reflejado cómo los distintos rangos de edad se distribuyen en los distintos tamaños de organizaciones. Notar que las filas suman 100% (aproximadamente por el redondeo) por ende el total de filas es las personas que respondieron ese dato (orgSize).

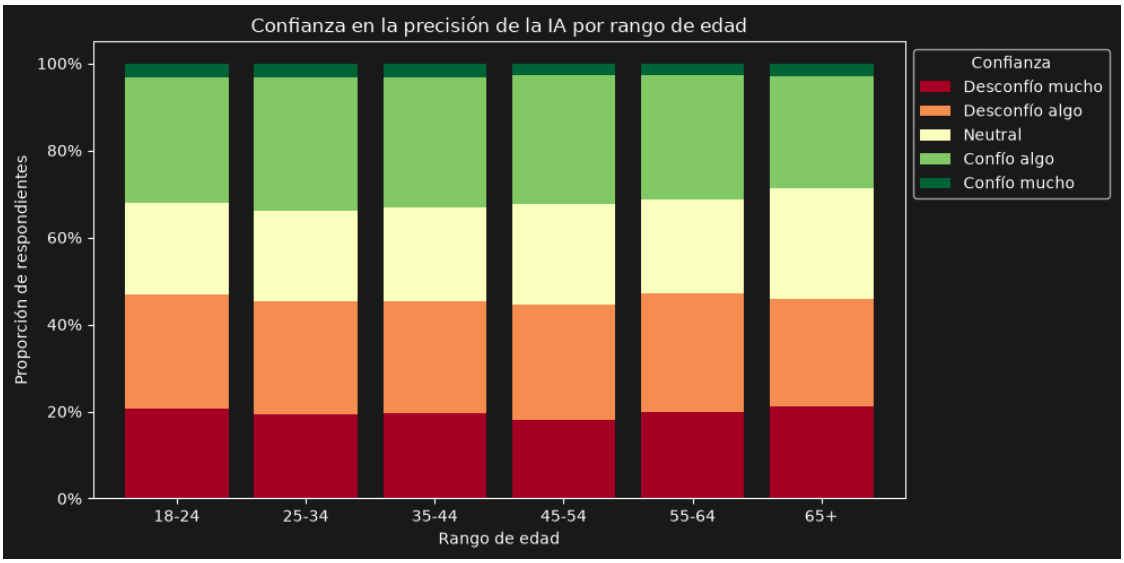


Esta otra tabla nos muestra cómo se distribuyen los grupos de tipos de trabajos en los rangos de edad.

Con estas tablas concluimos que no parecía muy aprovechable analizar los grupos por rangos de edad o tipo de trabajo por eso después decidimos comparar los promedios de las distintas variables Likert sobre la IA también según los rangos de edad y, aunque no notamos diferencias, nos pareció curioso que todas las variables fueron mayormente positivas salvo la confianza; entonces decidimos graficar y vimos los siguientes resultados:

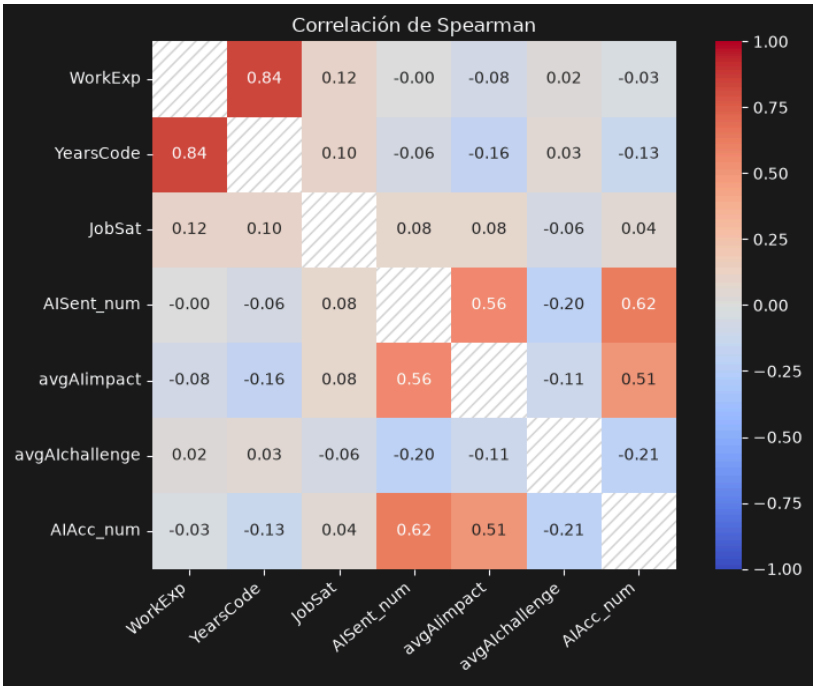


En la figura puede verse como el promedio se distribuye equitativamente en los rangos de edad. Notar que los jóvenes sienten más impacto y que la confianza es la única cuyo promedio está debajo de la mitad (3)



En las barras podemos ver que la culpa del promedio bajo es principalmente por los pocos resultados de alta confianza. Y también notar que menos del 40% confían y más del 40% desconfían en todos los casos.

Por último, hicimos una matriz de correlación para buscar qué variables podrían estar correlacionadas, y se vio así:



Matriz de correlación: Nos da pistas de una correlación alta entre WorkExp y YearsCode (evidente) Confianza y sentimiento y ninguna relación inversa alta en estas variables cuantitativas elegidas.

3. Hipótesis y resolución

3.1. Hipótesis 1:

3.1.1. Definición de la hipótesis

“Más del 30% de los usuarios que respondieron la encuesta usan como sistema operativo Linux u otro software libre”.

Esta hipótesis plantea una pregunta que aborda la incógnita sobre la adopción real de herramientas de código abierto en la vida cotidiana de los desarrolladores. Muchos afirman que Linux es el sistema preferido en el mundo de la programación por su flexibilidad, y sin embargo, otros dicen que en su tiempo libre la mayoría sigue usando opciones comerciales (como Windows o macOS) por simple comodidad. Este test nos permitirá evaluar si este grupo de desarrolladores tiene una preferencia por el software libre lo suficientemente fuerte como para superar el umbral del 30% del mercado. Decir también que la hipótesis evalúa únicamente el uso personal (OpSysPersonal use), pero no plantea si esta elección está condicionada por otros factores (como el costo de los equipos o el nivel de experiencia del usuario), datos que podrían ser importantes a la hora de sacar las conclusiones definitivas (link).

3.1.2. Estrategia de abordaje

Para poner a prueba la hipótesis planteada, se seleccionó dentro del conjunto de datos de Stack Overflow la variable correspondiente al uso de sistemas operativos en el entorno personal. Esta pregunta permite analizar las herramientas elegidas libremente por los desarrolladores fuera de los requerimientos o restricciones de su espacio laboral.

El primer paso del proceso consistió en el diagnóstico de la calidad de la información. Sobre un total inicial de 49191 observaciones, se detectaron 17774 registros con valores nulos, lo que representaba un 36.13 por ciento de datos faltantes en la columna. Dado que se trataba de una pregunta de respuesta optativa en el formulario de la encuesta, se decidió aplicar una regla de eliminación por lista sobre estos registros no respondidos, conservando una base limpia de 31417 desarrolladores con información completa.

Debido a que el formulario permitía la selección múltiple de opciones dentro de una misma celda con valores separados por punto y coma, se requirió una transformación en la granularidad de los datos. Mediante el desarmado y la expansión de las cadenas de texto, la unidad de análisis pasó de ser el desarrollador individual a ser cada mención registrada de un sistema operativo. Este procedimiento de aplanamiento permitió recuperar un total de 76935 menciones individuales.

Con el propósito de resolver la alta dispersión de datos causada por la presencia de más de quince opciones diferentes, se diseñó un criterio de reclasificación en macro-familias. Las respuestas se agruparon en cinco categorías principales: Linux y GNU (que unificó distribuciones como Ubuntu, Debian, Fedora, Arch, Pop OS, Red Hat, NixOS y versiones no WSL), macOS y Apple, Windows en formato nativo, Windows Subsystem for Linux (WSL), y una categoría para sistemas móviles u otros entornos minoritarios. Esta consolidación estructuró la tabla de frecuencias sobre la cual se ejecutó la prueba estadística.

3.1.3. Resultados obtenidos y discusión

El procesamiento de los datos y la ejecución de la prueba sobre la proporción arrojaron los siguientes resultados clave (link):

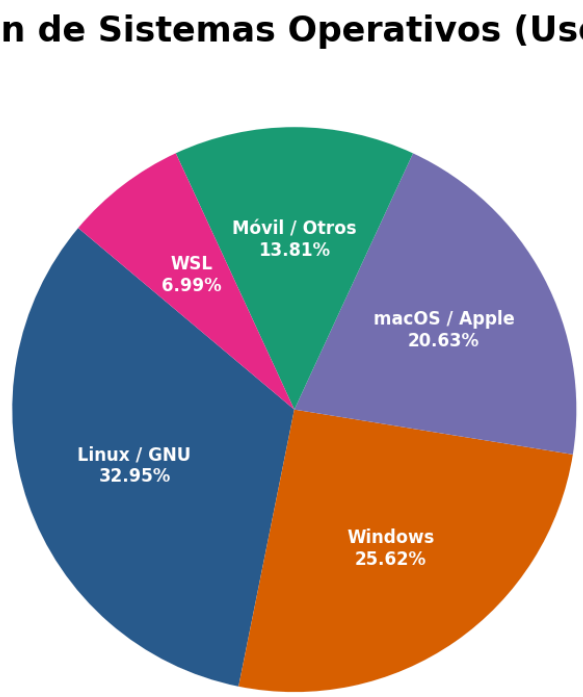


Figura 1. Distribución porcentual de menciones por macro-familia de sistemas operativos en entorno personal ($N = 76.935$).

- **Frecuencias observadas:** Sobre el total de 76935 menciones individuales analizadas, la categoría de Linux y GNU registró 25208 menciones, alcanzando una proporción muestral observada del 32.77 por ciento.
- **Evaluación del test estadístico:** Al contrastar la proporción observada del 32.77 por ciento frente al valor teórico del 30 por ciento, se obtuvo un estadístico Z de 16.74 desviaciones estándar por encima de la media esperada en la hipótesis nula, con un valor p inferior a 0.0001.
- **Decisión e interpretación:** Dado que el valor p resulta significativamente menor al nivel de significancia establecido de 0.05, se toma la decisión formal de rechazar la hipótesis nula. En consecuencia, se concluye que existe evidencia estadística suficiente para afirmar que la proporción de desarrolladores que utilizan Linux en su entorno personal es superior al 30 por ciento estimado teóricamente.

3.2. Hipótesis 2:

3.2.1. Definición de la hipótesis

“La satisfacción laboral (JobSat) difiere según la modalidad de trabajo (RemoteWork), siendo mayor en remoto que en presencial.”

En la industria tecnológica global, las políticas de presencialidad y flexibilidad horaria se han convertido en un eje central de debate. El trabajo remoto suele asociarse a mayor autonomía, eliminación de tiempos de traslado y mejor equilibrio entre vida personal y profesional. Por el contrario, los esquemas rígidos presenciales pueden generar mayor desgaste o insatisfacción. Evaluar esta hipótesis permite verificar si los datos empíricos de la encuesta respaldan la percepción de que la flexibilidad geográfica impacta positivamente en el bienestar del desarrollador.

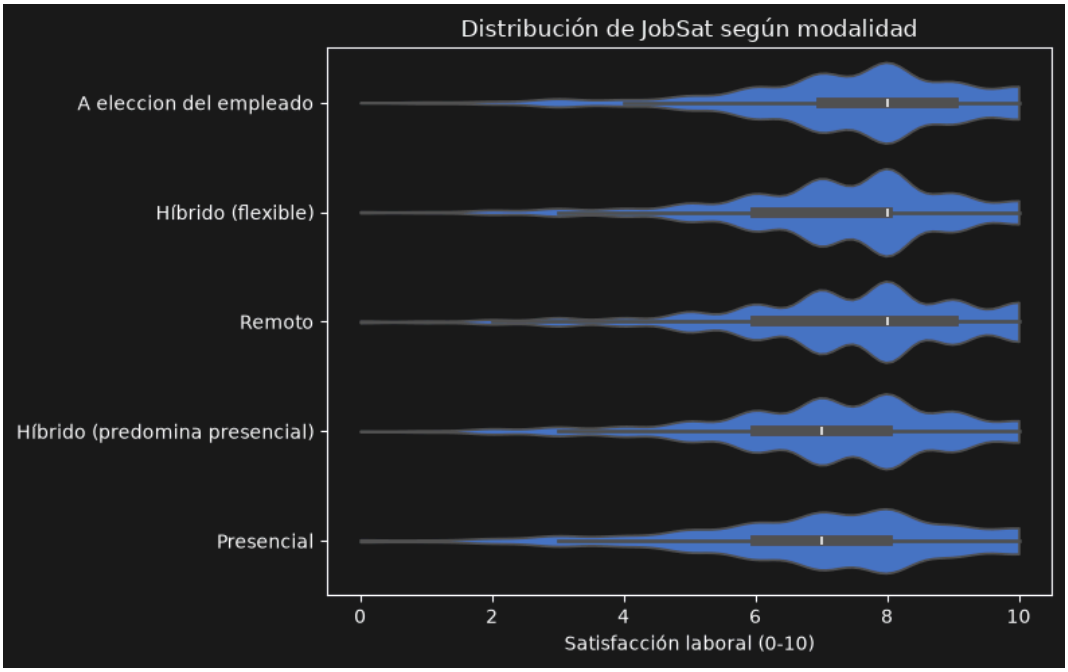
3.2.2. Estrategia de abordaje

Para poner a prueba la hipótesis se trabajó con dos variables del conjunto de datos: por un lado, la variable cualitativa ordinal JobSat, que registra la satisfacción laboral en una escala del 0 al 10, y por otro lado la variable cualitativa nominal RemoteWork, donde se encuentran 5 categorías: Remoto, Presencial, Híbrido (predomina presencial), Híbrido (flexible) y “A elección del empleado”. Estas categorías fueron establecidas en inglés y nosotros, para facilitar la lectura, las traducimos al español (link).

El primer paso fue quedarnos con las observaciones que respondieron ambas preguntas. Como JobSat tiene una gran cantidad de nulos (22521), al eliminar los casos incompletos (link) la base de análisis quedó

en 22797 desarrolladores. Los tamaños de grupo fueron muy desiguales: Remoto es el más numeroso (7908) y “A elección del empleado” el menos numeroso (2848).

Luego se verificaron los supuestos para elegir la técnica de validación. Como la hipótesis compara más de dos grupos independientes, la opción habitual sería un ANOVA, pero la variable JobSat es ordinal y, además, el test de Levene rechazó la igualdad de varianzas entre grupos (link), por lo cual no se cumple la homocedasticidad. Por eso se utilizó Kruskal-Wallis, ya que no exige normalidad ni varianzas iguales.



En la figura se pueden ver las distribuciones en los grupos en cada violin-plot. Notar cómo aunque las distribuciones son similares las medianas son claramente diferentes acercándose a la izquierda(positivo) .

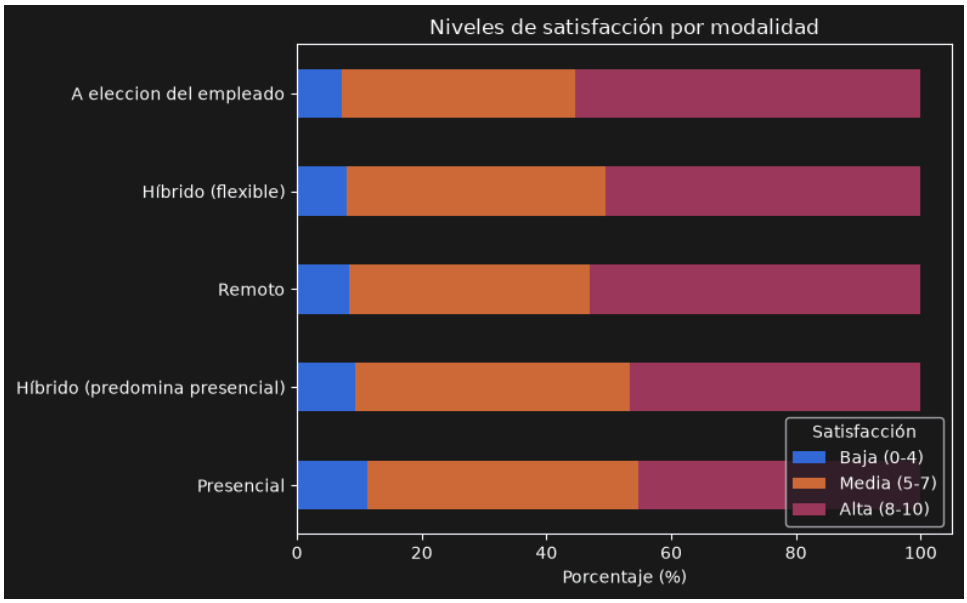
3.2.3. Resultados obtenidos y discusión

Modalidad	**n**	**Media**	**Mediana**	**Desvio**
A elección del empleado	2848	7.43	8	1.83
Remoto	7908	7.32	8	1.97
Hibrido (flexible)	4046	7.21	8	1.83

Hibrido (predomina presencial)	4499	7.08	7	1.89
Presencial	3496	6.99	7	2.05

Tabla en la cual se muestran los resultados obtenidos

Según los resultados, las modalidades con mayor flexibilidad (“A elección del empleado” y Remoto) tienen medias y medianas más altas que las otras modalidades. La relación entre la modalidad de trabajo y la satisfacción laboral es baja (las diferencias entre grupos son pequeñas), pero el test de Kruskal-Wallis detecta una diferencia significativa (link).



Aquí se puede ver más claramente las diferencias en los grupos en donde se nota que cuando hay trabajo remoto o electivo hay más satisfacción.

Con esto podemos decir que era de esperarse que las personas suelan estar más contentas con su trabajo cuando les dan a elegir, aunque esto después suponga otros problemas.Pero en esta encuesta los usuarios de Stack Overflow responden que su satisfacción suele ser mayor cuando el trabajo es a distancia. Dicho esto, podemos confirmar la hipótesis.

3.3. Hipótesis 3:

3.3.1. Definición de la hipótesis

“Al considerar conjuntamente el sentimiento y la confianza hacia la IA, la experiencia laboral y el desafío percibido, el impacto positivo promedio que sienten las personas al usar agentes de IA es mayor cuanto más grande es la organización y cuanto mayor es la satisfacción laboral del encuestado”.

Cuando observamos los agentes de IA, pensamos en cómo se dice que estos aumentan la productividad exponencialmente y en cómo nosotros, los estudiantes, no manejamos esas tecnologías; siempre las asociamos a grandes corporaciones, con una burocracia interna que fácilmente puede ser reemplazada por agentes automáticos. Por eso pensamos en esta hipótesis, en donde afirmamos que cuanto más grande es la organización, más se sienten beneficiadas en las tareas del día a día (más impacto positivo sienten) y que ese impacto va de la mano de trabajadores más satisfechos, por librarse de estas tareas tediosas.

Sin embargo, el impacto de los agentes puede depender de muchos factores a la vez: lo que la persona piensa de la IA en general, cuánto confía en ella, cuánta experiencia tiene o cuántos desafíos percibe en el uso de los agentes. Por eso planteamos la hipótesis de manera multivariada: queremos ver si el tamaño de la organización y la satisfacción laboral se siguen asociando al impacto cuando se consideran todas estas variables al mismo tiempo.

3.3.2. Estrategia de abordaje

Para abordar este análisis tuvimos que construir una variable con el promedio de las variables sobre el impacto que sentían que los agentes de IA tenían en distintas tareas (avgAIimpact), y otra con el promedio de los desafíos percibidos (avgAIchallenge) (link).

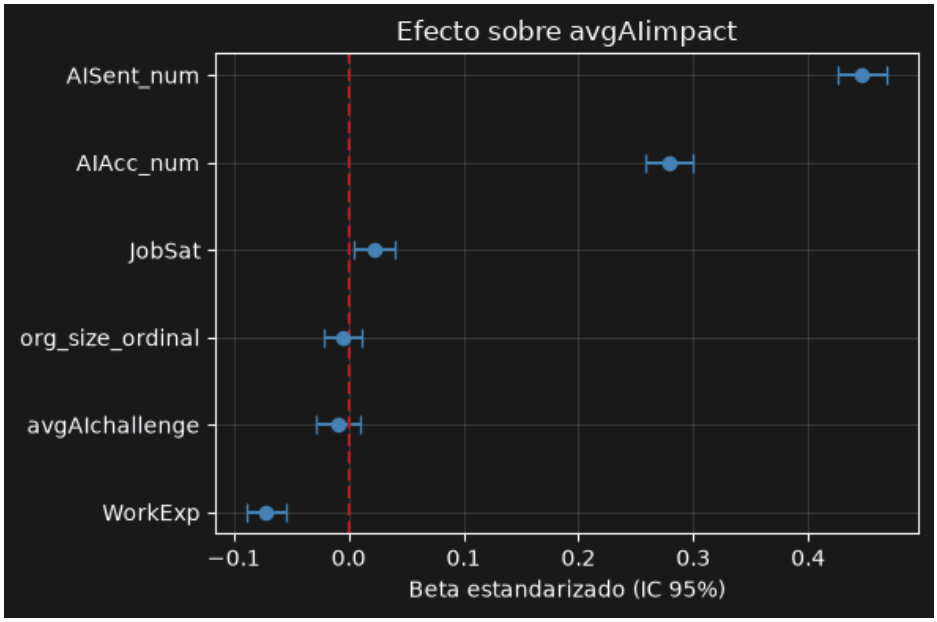
Como la hipótesis es multivariada, planteamos un modelo de regresión lineal múltiple con avgAIimpact como variable respuesta y, como variables explicativas, el tamaño de la organización (org_size_ordinal), la satisfacción laboral (JobSat), la experiencia laboral (WorkExp), el sentimiento (AISent_num) y la confianza (AIAcc_num) hacia la IA, y el desafío percibido (avgAIchallenge). Todas las variables fueron estandarizadas, de modo que los coeficientes (betas estandarizados) son comparables entre sí, y se usaron errores

estándar robustos (HC3). Solo se tomaron las filas con información en todas las variables, ya que los agentes dejan sin respuesta a la mayoría de las observaciones: de las 49191 filas quedaron 8019 (link).

Antes de interpretar el modelo revisamos la multicolinealidad mediante el VIF de cada variable. Luego rehicimos el modelo sacando las variables que no resultaron significativas en el primer modelo (avgAIchallenge y org_size_ordinal) para ver si mejoraba; al pedirse menos variables, quedaron 9736 observaciones.

3.3.3. Resultados obtenidos y discusión

En el primer modelo (n = 7872) las variables explican en conjunto alrededor del 42% de la variabilidad del impacto promedio (R^2 = 0.417). Las que más se asocian al impacto son el sentimiento (β = 0.449) y la confianza (β = 0.275) hacia la IA, ambas con $p < 0.001$. La experiencia laboral tiene una asociación negativa pequeña (β = -0.072; $p < 0.001$) y la satisfacción laboral una asociación positiva muy pequeña (β = 0.022; p = 0.014). El tamaño de la organización (β = -0.004; p = 0.576) y el desafío percibido (β = -0.011; p = 0.232) no mostraron asociación significativa. Los VIF fueron menores a 1.4 en todas las variables.



Aquí se puede ver gráficamente que valores su rango pasa por el 0 indicando que es una variable que no explica muy bien la regresión.

Al rehacer el modelo solo con el sentimiento, la confianza, la satisfacción laboral y la experiencia (n = 9485), los resultados se mantuvieron: R^2 = 0.407, sentimiento β = 0.44, confianza β = 0.273, experiencia β = -0.069 y satisfacción laboral β = 0.025 (p = 0.003).

Descubrimos que no estábamos en lo cierto con el tamaño de la organización: aun considerando el resto de las variables, no parece estar relacionado con el impacto de los agentes de IA. Descubrimos que el sentimiento y la confianza sí están relacionados, lo cual era razonable dado que una alta confianza y una buena predisposición se logran a través de resultados. La satisfacción laboral sí está asociada, pero de manera muy leve, no lo suficiente como para que lo consideremos un hecho.

Por último, hay que considerar que el modelo no es el más fiable: los tests sobre los residuos (Omnibus y Jarque-Bera) rechazan la normalidad y el análisis se hizo con una muestra reducida respecto del total. Pero aún así la hipótesis queda rechazada porque org_size no está linealmente asociado a el impacto promedio de los agentes de IA.

3.4. Hipótesis 4:

3.4.1. Definicion:

"Los desarrolladores que respondieron la encuesta de Argentina tienen

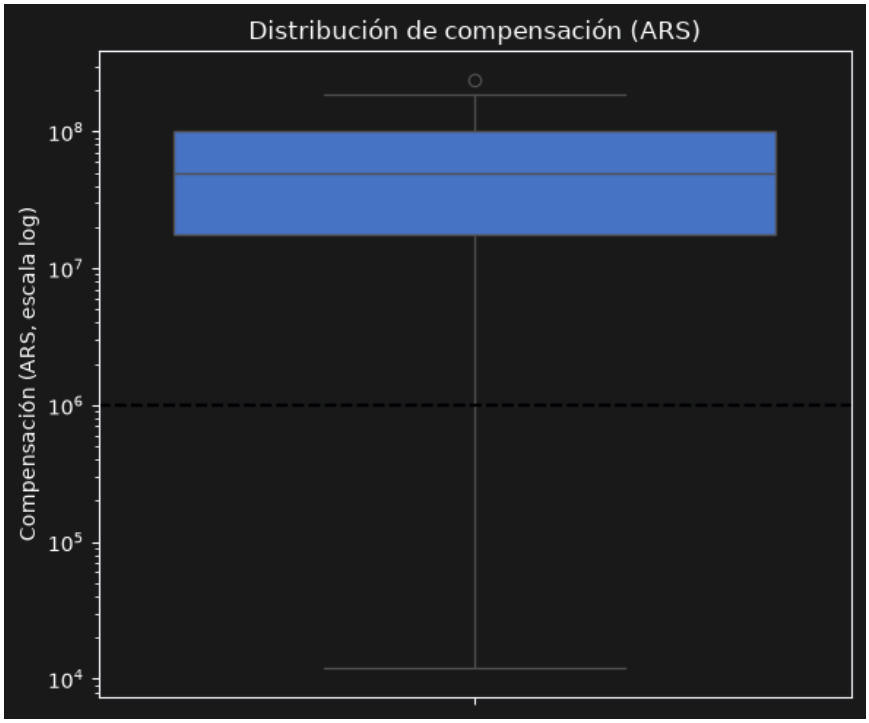
un salario 3 veces mayor al Salario Mínimo, Vital y Móvil (SMVM)"

Esta hipótesis plantea una pregunta que aborda la incógnita sobre el salario real medio de los desarrolladores. Muchos afirman que es un trabajo muy bien pago y sin embargo otros dicen que no ganan lo suficiente. Este test nos permite evaluar si este grupo de desarrolladores argentinos tiene un salario (aunque siga siendo bajo) aceptable. Decir también que la hipótesis no plantea las horas trabajadas y tampoco las tienen los datos pero podría ser importante a la hora de sacar las conclusiones (Link).

3.4.2. Estrategia de Abordaje:

Para abordar esta hipótesis decidimos primero tomar las variables “Currency”, que muestra la moneda en la que se cobra el salario (categórica) y “compTotal”(cuantitativa), que es el monto ganado por los desarrolladores anualmente, de las observaciones que afirmaban ser de Argentina. Vimos que algunas estaban en $ARS y otras en $USD por lo que tuvimos que estandarizar los valores en $ARS.

Decidimos ver como parecen distribuirse los valores y notamos valores exageradamente altos y otros muy bajos. Cabe recalcar que la columna en teoría representa el monto anual pero podría haber errores de ingreso ya que no se estila publicar esa información de esa manera en Argentina, y también podría haber casos en los que se ingresaron montos correspondientes al cobro por hora.



En la figura se puede ver como la gran mayoría de valores superan ARS $1.000.000($10^6$) incluso $10.000.000(10^7). Notar la escala logarítmica y entender que los valores menores a ARS$ 10.000 (10^5) probablemente sean errores.

De todas formas notamos que los valores altos no eran irrisorios (Todos menores a $USD 200.000 anual) y los menores decidimos dejarlos porque la tendencia nos daba la sensación que la mediana el salario si iba a ser 3 veces a pesar de tener estos valores tan bajos. Para realizar el test se probó la normalidad de los datos con shapiro-wilk y un QQ-plot, de ambas maneras vemos que no son normales, por eso deberíamos

usar un test no paramétrico, pero considerando los resultados obtenidos y al no ser un test tan potente no necesitamos ejecutarlo.

3.4.3. Resultados obtenidos y discusión:

Luego de calcular la media y mediana,las cuales se calcularon considerado con el SMVM de Junio de 2026 multiplicado por 13 (12 sueldos+aguinaldo) el resultado nos dio que efectivamente la mediana si era mayor a 3 SMVM incluso cuando consideramos la exigencia con cuestiones como sumar el aguinaldo lo cual no se estila en los cobros en $USD e incluso tomamos un salario mínimo que es más alto que el del periodo de la encuesta cuando se supondría que los salarios tambien deberian haber aumentado(Sobre todo en $ARS).

Aun así no dejamos de ver que el mercado del desarrollo de software es muy desigual, con valores que superan los $ARS 100.000.000 y muchos otros que no llegan a los $ARS 10.000.000 (debajo del umbral). Es obvio que no todos los datos son 100% fiables cuando se rellenan estas encuestas, hay tanto errores como equivocaciones deliberadas cuando se trata de ingresar el monto de dinero que uno cobra (también aproximaciones porque el salario anual no es fácil de calcular) e incluso la encuesta tiene observaciones de gente tanto en relación de dependencia como independientes, pero aun asi es notable la diferencia que hoy supone y es importante poder concluir que, como en todos los trabajos, no siempre se gana muchísimo dinero.

3.5. Hipótesis 5:

3.5.1. Definición:

“Los años de experiencia profesional influyen en la confianza en la precisión de las herramientas de IA”.

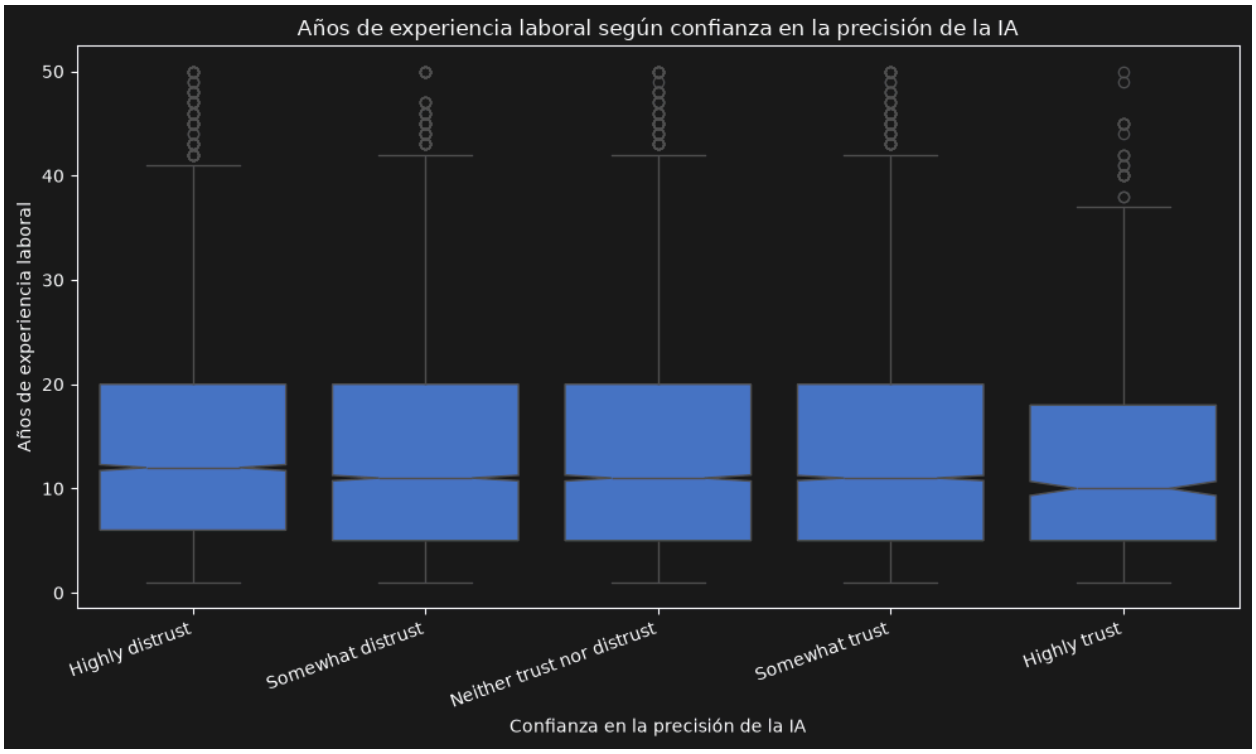
Cuando se trata de herramientas de tecnología nueva, se suele decir que las personas con más experiencia con tecnologías antiguas son más desconfiadas de los cambios y mejoras que la nueva tecnología supone, y la IA no es la excepción. Pero a veces estos prejuicios no suelen ser tan reales como creemos, y la experiencia profesional podría darnos un indicio de que las innovaciones que generan mucho revuelo en el mercado muchas veces son más falibles de lo que creemos. Por eso, tomando estos análisis, se plantea esta hipótesis para ver si la desconfianza en esta tecnología es propia de quienes ya tienen muchos años en el mercado laboral.

3.5.2. Estrategia de abordaje:

Para analizar esta hipótesis decidimos tomar las variables “WorkExp”, variable cuantitativa que representa los años trabajados, y “AIAcc”, que responde a la pregunta “How much do you trust the accuracy of the output from AI Software tools as part of your development workflow?” y se divide en Highly trust, Somewhat trust, Neither trust nor distrust, Somewhat distrust y Highly distrust (Link).

Parece un análisis simple; sin embargo, WorkExp tenía valores poco verosímiles: había personas que afirmaban haber trabajado 100 años. Esto nos llevó a desconfiar de muchos valores posibles: ¿cómo podíamos saber si las personas no se equivocaban poniendo la edad en esta variable? Decidimos confiar en la edad domo ya de vio en la limpieza de la variable y borramos los valores mayores a 50 porque eran pocos e inverosímiles.

Primero miramos en algunos boxplots si las diferencias parecían ser significativas y vimos que no era así. No se puede graficar un scatter plot porque las variables discretas dificultan la visualización.



En la figura podemos ver cómo se distribuye la confianza de la IA según la experiencia laboral. Notar que los notches se solapan bastante pero los últimos 2 grupos se diferencian lo que nos da una pista del resultado de la hipótesis.

3.5.3. Resultados obtenidos y discusión

Decidimos medir la correlación de las variables con los tests de Pearson y Spearman, y dieron resultados muy cercanos a 0 (-0.036 y -0.034, respectivamente). Por otro lado, corrimos un test de Kruskal-Wallis porque, ante la ausencia de normalidad y homocedasticidad, era el único que podíamos usar. Dado que había una diferencia significativa con muchos datos este test es sensible a pequeñas diferencias, y esa es la diferencia mínima que puede verse en los coeficientes.

La confianza o desconfianza en la IA, según nuestros datos, es bastante transversal a la experiencia laboral, lo que puede indicar que los valores de esta variable se deben a otros factores, como las experiencias personales con el uso de la misma (con eso se justifica esa leve relación), lo cual parece tener sentido, ya que muchos profesionales experimentados no desconfían ciegamente de las nuevas tecnologías, solo tienen el criterio para saber dónde usarlas.

3.6. Hipótesis 6:

3.6.1. Definición de la hipótesis:

¿Están los distintos niveles de satisfacción en los distintos aspectos del trabajo actual relacionados con la consideración de un cambio de rol o de carrera?

Es evidente pensar que la consideración de un cambio de trabajo está definida por el nivel de satisfacción de los distintos aspectos del mismo, y que algunos aspectos influyen lo suficiente como para ser el determinante de un cambio de rol y de trabajo, un cambio de vida.

Entonces, con las variables con las que contamos, elegimos mirar si en nuestro dataset podemos encontrar alguna relación que nos permita sacar alguna conclusión.

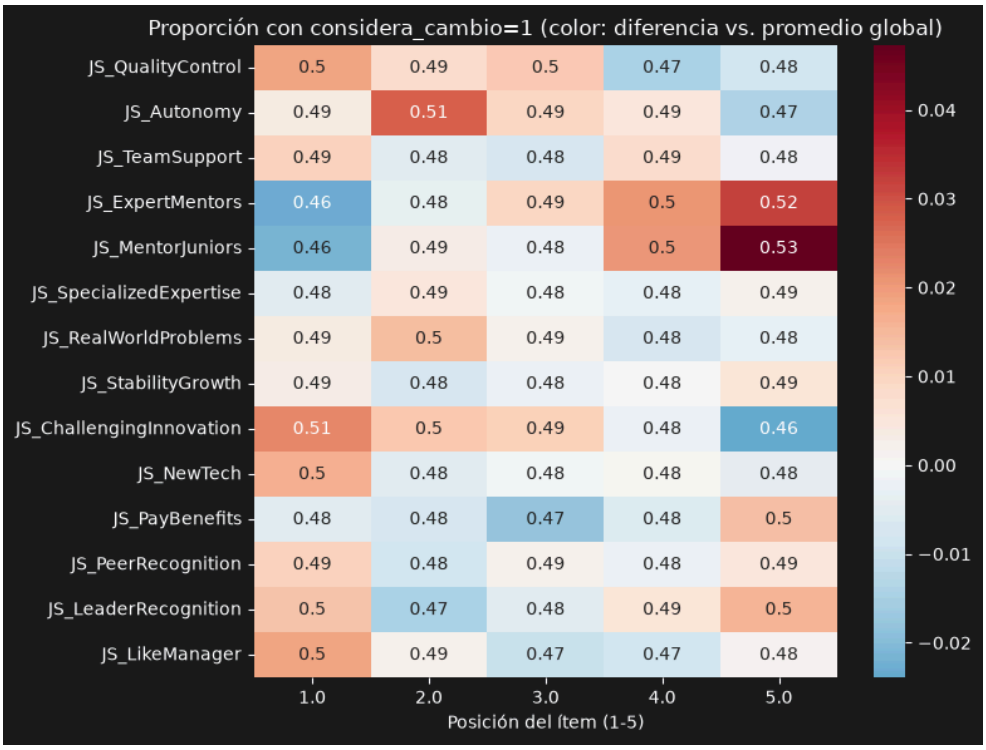
3.6.2. Estrategia de abordaje

Para abordar esta hipótesis tuvimos que hacer un tratamiento complejo. Los JobSatPoints, que definían nuestra satisfacción laboral en distintas áreas, eran un ranking que tuvo que ser reinterpretado como alta satisfacción si el puesto era alto y baja satisfacción si el puesto era bajo, aunque podría no ser necesariamente así (Link). Esto nos trajo problemas porque las variables no eran totalmente independientes en su decisión. Por otro lado, NewRole tenía valores que afirman un cambio de rol efectivo, que no era el punto a tratar en esta hipótesis, por eso los quitamos. Aquí abrimos dos caminos y

mantuvimos ambos: dejar 3 grupos en una escala de consideración (nunca, poco, mucho) o dejar un análisis binario como considera (sí/no).

Entonces la idea era algo así: explorar posibles grupos corriendo clusterings no supervisados y evaluando si esos grupos se corresponden con los grupos construidos por las variables.

Pero antes de eso teníamos que resolver la multicolinealidad del problema y, para eso, decidimos quitar una de las variables, la que estaba más equitativamente repartida en los dos grupos de considera_cambio. Eso lo decidimos mediante un test chi-cuadrado que nos permitió ver qué variables individualmente tenían más tendencia hacia cierto grupo de consideración (Link)

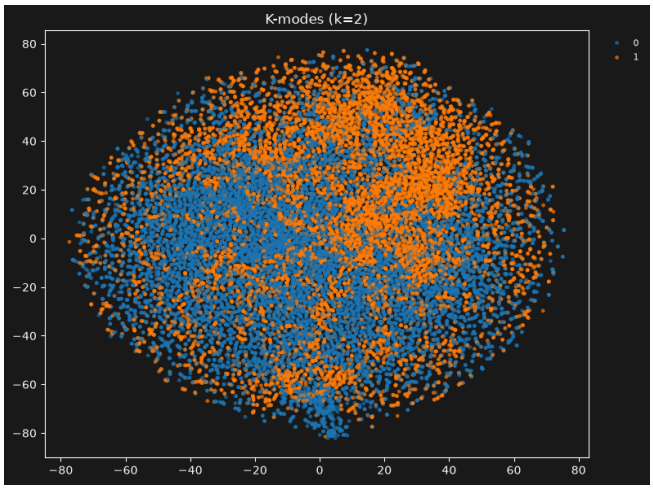


Esta tabla nos permite ver en principio que no hay ninguna tendencia muy alta o baja, pero si nos permite decidir qué variables quitar para probar si surge algun grupo con ciertas condiciones.

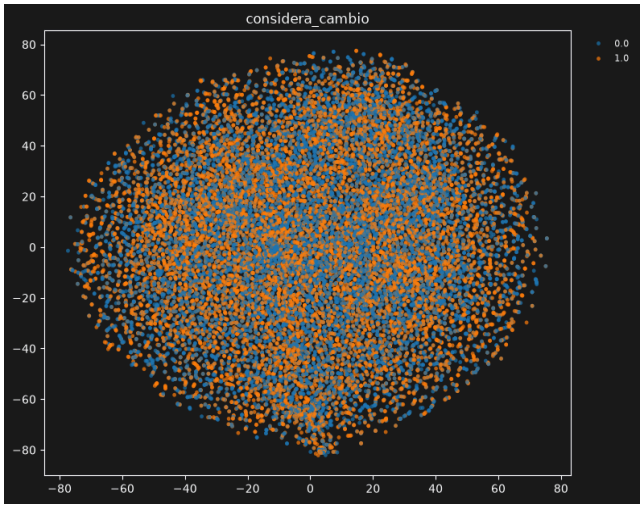
Primero corrimos un PCA para ver si había algún componente que explicara suficiente varianza para poder trabajar con eso, y recién a partir del 6.º componente se veía una varianza del 60%. Por esto corrimos el clustering k-means y graficamos un t-SNE para ver si había alguna división; a su vez, en el mismo t-SNE pintamos los puntos según la variable binaria y según NewRole, que tenía 3 categorías. Y aunque el grupo del cluster parecía separar los puntos, los tres gráficos mostraban una nube mezclada, muy mezclada, en los casos pintados con las variables. Esto nos mostraba que los clusters no estaban reflejando los grupos

que queríamos, lo que nos da un indicio de que estas variables no tenían mucho que ver. Y esto se podía ver en el Elbow plot y en la silueta: no había un k claro en el codo y la silueta nunca supera el 0.1.

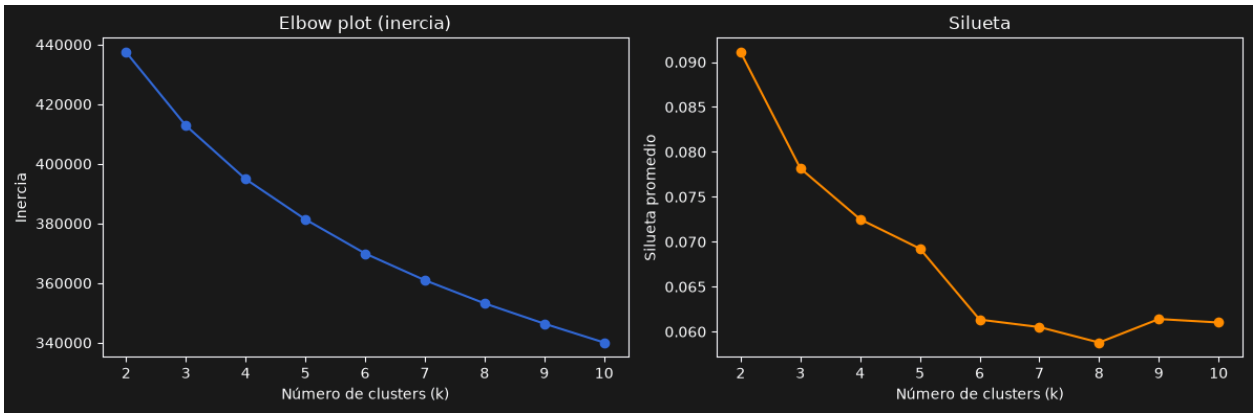
Luego decidimos probar con k-modes, otro modelo de clustering más apropiado para las variables que teníamos, aunque aun así no conseguimos agrupar de una manera visible.



Este gráfico representa los clusters en 2 dimensiones para k=2 se puede ver que la distribución de los grupos no es uniforme. Los gráficos de tsne pueden salir distintos en cada ejecución por la semilla aleatoria del test. Además no buscar interpretación a los ejes.



Este gráfico funciona a modo informativo y pinta los grupos según el color que deberían tener si el clustering indicará una división de grupos como la que estamos buscando. La diferencia entre los gráficos nos indica que los grupos del clustering no parecen tener relación con los buscados



En los siguientes gráficos se ve que no hay un codo ni una silueta alta en la agrupación, no se encuentran grupos claros a la hora de hacer una división.

Además, las tablas de comparación nos decían que la distribución de los datos en el cluster era casi aleatoria cuando la comparábamos con considera_cambio o new_role.

Por eso dimos por finalizada la búsqueda, pero antes decidimos tomar, a modo exploratorio, solo las variables que individualmente más dispares eran en el heatmap de chi-cuadrado. Aunque entendemos que ya podemos concluir que los grupos que se forman no son lo que los clusters marcaban, ni que tampoco hay clusters muy claros, quisimos ver si con menos variables la distribución cambiaba. Así que elegimos las cuatro variables más representativas JS_Autonomy, JS_ExpertMentors, JS_MentorJuniors, JS_ChallengingInnovation y corrimos de nuevo el clustering. Como era de esperarse, dio los mismos resultados.

3.6.3. Resultados obtenidos y discusión

Podemos concluir que no encontramos evidencia de que, en el dataset, los aspectos de satisfacción laboral influye en la decisión de un cambio de rol; por eso no pudimos encontrar indicios de posibles grupos, y los pequeños acercamientos se deben más a la aleatoriedad de la distribución, como vimos en la tabla de un grupo el 51% son correctas y el 48% del otro grupo son correctas lo que no mejora una distribución trivial(son 2 grupos posibles). Quizá es porque las variables no fueron pensadas para usarse de ese modo y el ranking condiciona la distribución.

Por lo pronto, podemos pensar que quizá en la vida laboral, a la hora de tomar la decisión de un cambio de rol, las personas valoran distintas cosas; no olvidemos que el dataset es global, con personas que, aunque

son todas cercanas al mundo de la tecnología, tienen distintos criterios y gustos a la hora de elegir cambiar de trabajo.

4. Conclusiones

A lo largo de este análisis nos encontramos con muchas particularidades, algunas se trataban de errores propios del modelo de recolección pero muchas otras veces las observaciones nos mostraban que la realidad a veces es muy distinta a lo que se dice en los medios o las redes.

Más allá de los resultados, el trabajo nos mostró lo importante que es la preparación de los datos: el dataset tenía variables con mala organización, muchos nulos y valores poco verosímiles (como personas con 100 años de experiencia), y cada decisión de limpieza o imputación condiciona lo que después se puede concluir. También vimos que algunas variables no fueron pensadas para usarse de la forma en que las usamos, como los rankings de satisfacción laboral de la Hipótesis 6.

Respecto de las hipótesis que planteamos, hubo algunas que los datos no respaldan. La Hipótesis 3 fue rechazada, porque el tamaño de la organización no está linealmente asociado al impacto promedio de los agentes de IA, que se relaciona sobre todo con el sentimiento y la confianza hacia la IA. En la Hipótesis 6 no encontramos evidencia de que los aspectos de satisfacción laboral expliquen la consideración de un cambio de rol.

En cambio, hubo hipótesis que no pudimos desmentir, lo que no las hace verdaderas en todos los casos, pero por lo menos para este grupo de estudio podemos afirmar que sí. En la Hipótesis 1, Linux y GNU alcanzó el 32.77% de las menciones de sistemas operativos de uso personal, por encima del 30% planteado, aunque la distribución entre sistemas operativos es bastante pareja. En la Hipótesis 2, la satisfacción laboral resultó algo mayor en las modalidades más flexibles (“A elección del empleado” y Remoto): la relación es baja, pero el test detectó una diferencia significativa, por lo que el trabajo remoto tiene respaldo como beneficio, aunque con diferencias pequeñas. En la Hipótesis 4, la mediana de la compensación de los desarrolladores argentinos superó 3 veces el SMVM, aunque con mucha desigualdad entre los datos, así que no siempre se gana muchísimo dinero. En la Hipótesis 5, la experiencia laboral mostró una relación casi nula, aunque inversa, con la confianza en la IA.

Esto nos hace pensar en el grupo de estudio elegido: ¿es realmente Stack Overflow hoy una fuente fiable de información a la hora de analizar a las personas que trabajan con software? Por el momento no podremos saberlo del todo: se trata de una encuesta respondida por usuarios de la plataforma que decidieron participar, con preguntas de respuesta optativa y de alcance global, por lo que sus resultados

describen a este grupo y no necesariamente a todas las personas que trabajan con software. Aun así, sí podemos pensar en lo importante que es no dejarse llevar por lo que se dice popularmente gracias a los resultados.

No vamos a salvarnos de la desinformación, pero cuando hay datos es inteligente tomarse el tiempo de analizarlos y así lograr descubrir la verdad.

Referencias

- Stack Overflow Developer Survey 2025 – dataset en Kaggle: Stack Overflow Developer Survey 2025 .
- Stack Overflow Developer Survey 2025 – resultados (results.csv) descargados en el código: enlace.
- Stack Overflow Developer Survey 2025 – esquema de preguntas (schema.csv) descargado en el código: enlace.
- Secretaría de Trabajo, Empleo y Seguridad Social, Resolución 9/2025 (Boletín Oficial, 3/12/2025): Salario Mínimo, Vital y Móvil de junio de 2026 = $367.800 mensuales (Hipótesis 4). Resoluciones: Consejo Nacional del Empleo, la Productividad y el Salario Mínimo, Vital y Móvil (Argentina.gob.ar). Valor de junio de 2026: Infobae, 8/6/2026.
- Banco de la Nación Argentina, cotización del dólar oficial (venta): $1.570 al 5/11/2026, valor usado en el código como tasa_usd (Hipótesis 4). Consulta: El Cronista, 5/11/2026.
- Librerías utilizadas en el código: pandas, NumPy, SciPy, statsmodels, scikit-learn, kmodes, matplotlib y seaborn.